

Predição de Mortes por Tuberculose Utilizando Aprendizado de Máquina

Tales de Campos Hernandez

Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

10408846@mackenzie.br; RA 10408846

Resumo. *Este projeto tem como objetivo aplicar técnicas de Inteligência Artificial para analisar e prever o número estimado de mortes por tuberculose (todas as formas) a cada 100.000 habitantes em diferentes países e períodos históricos. Utilizando dados da Organização Mundial da Saúde (OMS) disponibilizados via Gapminder, serão explorados padrões temporais, regionais e socioeconômicos relacionados à tuberculose, com o intuito de identificar fatores críticos que afetam a mortalidade. Pretende-se aplicar modelos de Machine Learning para criar um sistema preditivo que auxilie no monitoramento e combate da doença.*

Palavras-chave: *Inteligência Artificial; Aprendizado de Máquina; Tuberculose; Predição; Saúde Pública.*

Abstract. *This project aims to apply Artificial Intelligence techniques to analyze and predict the estimated number of tuberculosis deaths (all forms) per 100,000 inhabitants in different countries and historical periods. Using data from the World Health Organization (WHO) available via Gapminder, temporal, regional, and socioeconomic patterns related to tuberculosis will be explored to identify critical factors affecting mortality. The goal is to apply Machine Learning models to create a predictive system that aids in monitoring and combating the disease.*

Keywords: *Artificial Intelligence; Machine Learning; Tuberculosis; Prediction; Public Health.*

1. Introdução

a. Contextualização

A tuberculose é uma das doenças infecciosas mais letais do mundo, afetando milhões de pessoas todos os anos. Apesar dos avanços na medicina, ainda representa um grande desafio de saúde pública, especialmente em países de baixa e média renda.

b. Justificativa

A análise de dados históricos pode auxiliar governos e organizações internacionais a direcionarem políticas públicas e recursos para o combate da

tuberculose. O uso de Inteligência Artificial permite identificar padrões e prever cenários futuros, o que pode contribuir para a redução da mortalidade.

c. Objetivo

- Realizar uma análise exploratória dos dados históricos de mortalidade por tuberculose;
- Aplicar modelos de Machine Learning (classificação/regressão) para prever a evolução da mortalidade;
- Avaliar o desempenho dos modelos e interpretar os resultados obtidos.

d. Opção do projeto

Framework: utilização do scikit-learn para análise e modelagem preditiva.

2. Descrição do Problema

Apesar dos esforços da OMS e governos locais, a tuberculose continua a ser uma das principais causas de morte em diversos países. A previsão da mortalidade com base em dados históricos pode auxiliar na tomada de decisão e no direcionamento de recursos. O problema consiste em desenvolver um modelo de aprendizado de máquina capaz de prever a taxa de mortes por tuberculose em diferentes regiões.

3. Aspectos Éticos e Responsabilidade

O uso da IA em saúde exige responsabilidade. Modelos preditivos não substituem diagnósticos médicos, mas podem apoiar políticas públicas. É importante garantir que os dados sejam tratados de forma ética, evitando vieses geográficos ou socioeconômicos que possam comprometer a interpretação. Além disso, os resultados devem ser apresentados de forma transparente, sem criar pânico ou interpretações equivocadas.

4. Dataset, Análise Exploratória e Preparação dos Dados

O dataset utilizado foi obtido no portal Gapminder (<https://www.gapminder.org/data/>), com origem nos dados oficiais da Organização Mundial da Saúde (WHO) (<https://www.who.int/tb/en/>). Ele contém o número estimado de mortes por tuberculose (todas as formas) por 100.000 habitantes em diversos países e territórios, no período de 2000 a 2023.

O arquivo possui 214 linhas (países/regiões) e 24 colunas de anos (2000 a 2023), além da coluna de identificação do país.

Durante a análise exploratória:

- Identificou-se que há valores ausentes em alguns anos iniciais (2000–2010), mas a partir de 2011 os dados estão completos.

- Observou-se que a média global de mortalidade por tuberculose vem diminuindo desde 2000, embora alguns países, sobretudo na África Subsaariana, apresentem taxas ainda muito elevadas.
- Em 2023, os países mais críticos incluem Lesoto, República Centro-Africana e Gabão, com valores superiores a 100 mortes por 100k habitantes.

Para a preparação dos dados:

- Os valores ausentes foram tratados por meio de imputação pela média.
- Foi feita a normalização (StandardScaler) para garantir escalas comparáveis entre as variáveis temporais.
- Definiu-se como variáveis explicativas (X) os anos de 2000 a 2022, e como variável alvo (y) o ano de 2023, permitindo avaliar modelos de regressão para prever a mortalidade recente a partir de dados históricos.
- Por fim, os dados foram divididos em treino (80%) e teste (20%), garantindo a avaliação adequada dos modelos de Machine Learning.

5. Metodologia

O projeto utilizará técnicas de Ciência de Dados e Aprendizado de Máquina para prever a taxa estimada de mortes por tuberculose (TB) por 100.000 habitantes em diferentes países. O processo metodológico será estruturado em etapas:

1. Coleta e Organização dos Dados

- a. Utilização de dataset disponibilizado pela Organização Mundial da Saúde (WHO), contendo estimativas anuais de mortalidade por todas as formas de tuberculose entre 2000 e 2023.

2. Análise Exploratória dos Dados (EDA)

- a. Identificação de padrões, tendências históricas e diferenças regionais.
- b. Verificação de valores ausentes e inconsistências nos registros.
- c. Visualização temporal das séries de mortalidade.

3. Pré-processamento e Preparação dos Dados

- a. Tratamento de valores ausentes por imputação.
- b. Normalização das variáveis para garantir melhor desempenho dos modelos.
- c. Separação entre variáveis explicativas (anos 2000–2022) e variável alvo (ano 2023).

4. Modelagem Preditiva

- a. Teste de diferentes algoritmos supervisionados de regressão, incluindo Regressão Linear, Ridge, Lasso e Random Forest.
- b. Validação cruzada e comparação entre modelos com base em métricas como R^2 (coeficiente de determinação), MAE (Erro Absoluto Médio) e RMSE (Raiz do Erro Quadrático Médio).

5. Avaliação e Interpretação dos Resultados

- a. Comparação entre valores reais e previstos para países do conjunto de teste.
- b. Análise da acurácia dos modelos e discussão sobre limitações (ex.: variáveis externas não incluídas, como condições socioeconômicas, campanhas de saúde pública e acesso a tratamento).

Para a etapa de modelagem, foram treinados quatro algoritmos distintos: Regressão Linear, Ridge, Lasso e Random Forest. A validação dos modelos foi realizada utilizando a técnica de validação cruzada (*Cross-Validation*) com 5 *folds* (partições), garantindo que os resultados fossem robustos e não enviesados por uma única divisão de dados. A métrica principal para escolha do melhor modelo foi o coeficiente de determinação (R^2), observando-se também o Erro Absoluto Médio (MAE) e a Raiz do Erro Quadrático Médio (RMSE) para avaliar a magnitude dos erros de predição.

6. Resultados

Os experimentos realizados compararam o desempenho de modelos lineares (Linear Regression, Ridge, Lasso) e não-lineares (Random Forest) na tarefa de prever a mortalidade por tuberculose no ano de 2023, baseando-se no histórico de 2000 a 2022.

A Tabela 1 resume as métricas de desempenho obtidas nos dados de teste:

Tabela 1. Comparativo de Desempenho dos Modelos

model	r2	mae	rmse	
1	Lasso	0.963	2.805	5.262
2	Ridge	0.946	2.975	6.366

3	RandomForest	0.900	4.001	8.628
4	LinearRegression	0.867	4.304	9.953

O modelo Lasso apresentou o melhor desempenho geral, alcançando um R^2 de aproximadamente 0.963, o que indica que o modelo conseguiu explicar 96,3% da variabilidade dos dados de mortalidade em 2023. O modelo utilizou o hiperparâmetro de regularização α : 1.0. Observou-se que os modelos lineares (Lasso e Ridge) superaram o Random Forest e a Regressão Linear simples, sugerindo que a evolução da tuberculose nestes países segue tendências que se beneficiam da regularização para evitar *overfitting* (ajuste excessivo aos dados de treino).

Análise das Predições Ao aplicar o modelo Lasso para prever os dados de 2023, foi possível comparar os valores reais com os preditos. A análise de resíduos (diferença entre real e previsto) mostra que o modelo foi muito preciso para a maioria dos países, mas apresentou desvios em cenários específicos.

Destaques das predições (Valores por 100k habitantes):

- **Alta Precisão:** Em países com grandes populações e dados consistentes, o erro foi mínimo. Exemplo: Índia (Real: 22.0 / Predito: 22.94) e Paquistão (Real: 20.0 / Predito: 19.05).
- **Maiores Desvios:** Os maiores erros absolutos ocorreram em países com taxas historicamente instáveis ou muito altas. O maior erro foi observado no Timor-Leste (Erro abs: ~20.7) e na Nigéria (Erro abs: ~16.0). No caso do Timor-Leste, o modelo previu uma alta (60.7) superior à realidade (40.0), possivelmente influenciado por picos anteriores na série histórica que não se repetiram em 2023.

7. Conclusão

O projeto atingiu seu objetivo principal de construir um sistema preditivo capaz de estimar a mortalidade por tuberculose utilizando técnicas de Aprendizado de Máquina. A utilização de dados históricos da OMS permitiu treinar modelos com alta capacidade de generalização.

Conclui-se que:

1. **Eficácia do Modelo:** O algoritmo Lasso mostrou-se o mais adequado para este problema de séries temporais transformado em regressão, superando abordagens mais complexas como Random Forest. Isso indica que a tendência de

mortalidade por tuberculose possui uma forte componente linear e persistente ao longo dos anos.

2. **Relevância Prática:** Com um Erro Médio Absoluto (MAE) de aproximadamente 2.8 mortes por 100k habitantes, o modelo oferece uma estimativa confiável para auxiliar gestores de saúde pública. A capacidade de antecipar taxas de mortalidade permite identificar países que estão desviando da meta de erradicação da doença.
3. **Limitações e Trabalhos Futuros:** Embora o R^2 seja alto, os erros em países como Timor-Leste e Gabão sugerem que variáveis puramente históricas (anos anteriores) podem não ser suficientes para capturar mudanças bruscas causadas por fatores externos (como crises econômicas, guerras ou o impacto da pandemia de COVID-19 no sistema de saúde). Para trabalhos futuros, sugere-se a inclusão de variáveis socioeconômicas (PIB, investimento em saúde) para refinar as previsões nestes casos extremos.

9. Links

YouTube: <https://youtu.be/0CRaNBXOnWY>

GitHub: <https://github.com/TalesHernandes/applied-ai-real-scenario>

8. Referências

ORGANIZAÇÃO MUNDIAL DA SAÚDE (OMS). *Global Tuberculosis Report 2023. Disponível em: <<https://www.who.int/teams/global-tuberculosis-programme/data>>. Acesso em: 22 set. 2025.

GÉRON, Aurélien. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow. 2. ed. Sebastopol: O'Reilly Media, 2019.

JAMES, Gareth; WITTEN, Daniela; HASTIE, Trevor; TIBSHIRANI, Robert. An Introduction to Statistical Learning: with Applications in R. Nova York: Springer, 2013.

7. Bibliografia

ALPAYDIN, Ethem. *Introduction to Machine Learning*. 4. ed. Cambridge: MIT Press, 2020.

KUHN, Max; JOHNSON, Kjell. *Applied Predictive Modeling*. Nova York: Springer, 2013.

HAN, Jiawei; KAMBER, Micheline; PEI, Jian. *Data Mining: Concepts and Techniques*. 3. ed. Burlington: Morgan Kaufmann, 2012.

ORGANIZAÇÃO MUNDIAL DA SAÚDE (OMS). *Tuberculosis Data Portal*. Disponível em: <<https://www.who.int/teams/global-tuberculosis-programme/data>>. Acesso em: 22 set. 2025.